Towards conversational diagnostic AI

Introduzione

L'obiettivo dello studio è quello realizzare un modello LLM, in questo caso AMIE (Articulate medical Intelligence Explorer), ottimizzato per il dialogo diagnostico, raccolta dell'anamnesi, realizzazione di un piano terapeutico per il paziente. È basato sul modello PalM-2 di Google. Per gli autori l'obiettivo è quello di riuscire a creare questo sistema AI in modo da rendere la sanità più accessibile.

Dataset utilizzati

Sono stati utilizzati vari dataset per l'addestramento di AMIE tra cui dataset composti da:

- Risposte a domanda multipla
- Ragionamenti medici estesi
- Riepiloghi di fascicoli sanitari elettronici
- Trascrizioni di interazioni tra il personale medico

Durante la fase di addestramento il modello è stato esposto a una serie di attività tra cui: Risposte a domande in ambito medico, ragionamento medico e riassumere cartelle cliniche.

Per l'attività di ragionamento medico è stato utilizzato il dataset MedQA contenente domande a risposta multipla con 4 o 5 opzioni.

Il dataset utilizzato per i ragionamenti medici estesi è composto a sua volta da più dataset per un totale di 64 domande prese da: HealthSearchQA, LiveQA e Medication QA in MultiMedBench.

Mentre per l'attività di sintesi medica è stato utilizzato il dataset MIMC-III, un database pubblico contenente dati su pazienti ricoverati in terapia intensiva. MIMC-III contiene dati su circa 13 specialità mediche, per questo studio sono stati scelti 5 cartelle cliniche per ogni specialità con una lunghezza minima di 400 token e almeno una nota infermierista per ogni paziente.

Il dataset con le trascrizioni è stato concesso su licenza e contiene circa 100k trascrizioni audio di consultazioni, e dialoghi tra il personale medico. Le trascrizioni coprono circa 51 ambiti specialistici e 168 condizioni cliniche. Le discussioni avevano in media 150 turni; ogni conversazione ha permesso di estrapolare informazioni sui pazienti come la demografica, motivo della visita, storia clinica, e tipo della diagnosi. Per questo studio sono stati scelti dialoghi dove erano presenti solo il medicoe il paziente. Le trascrizioni audio sono state poi ripulite da annotazioni come “NON UDIBILE”. Il dataset è stato diviso nel 90% in training set e il restante 10% è stato usato come validation set.

Architettura modello AMIE

Spiegare l'immagine nella slide (parti da sinistra)

Abbiamo 3 componenti principali:

- A sinsitra il generatore di dialoghi simulati
- Al centro i dataset per l'addestramento
- A destra la catena di ragionamento per l'inferenza online

AMIE è caratterizzato da due loop di self-play:

- Un loop interno dove il modello sfrutta feedback contestuale su dialoghi simulati per migliorare le sue risposte con pazienti AI
- Un loop esterno dove questi dialoghi simulati veniva inclusi nelle successive iterazioni di fine-tuning.

AMIE sfrutta anche una catena di ragionamento per l'inferenza online permettendogli di migliorare le proprie risposte in base alla conversazione attuale per generare una risposta coerente e il più possibile simile a quella di un umano.

Sistema di autoapprendimento

I dati reali presentano problematiche che possono intaccare la scalabiltà e completezza del modello, per esempio non sono in grado di cogliere la complessità degli scenari in ambito medico. Presentano termini colloquioli, riferimenti impliciti e presentano del rumore.

Per superare queste limitazioni è stato realizzato un ambiente di autoapprendimento in un ambiente virtuale permettendo al modello di scalare le propria conoscenza e capacità. Questo ambiente è stato utilizzato per raffinare continuamente AMIE con un set di dialoghi in continua evoluzione in aggiunta ai dataset citati precedentemente.

Per la generazione dei dialoghi è stato realizzato un Framework multi-agente ad hoc, composto da 3 componenti:

- Generatore di scenari, AMIE sfruttando ricerche sul web per poter creare scenari su pazienti con determinate condizioni cliniche
- Generatore di dialogo simulato: composto da 3 agenti LLM tutti e 3 interpretati da AMIE, che svolgono il ruolo di medico, moderatore e paziente. Interagiscono tra di loro in un dialogo a turni.
- Feedback sul self-play: un quarto agente LLM svolge il ruolo di critico per poter dare un feedback all'agente medico e per aiutarlo a

migliorare.

Generatore di scenari

Il generatore di scenari si occupa di creare scenari con contesti realistici sfruttando ricerche sul web per varie condizioni cliniche.

Lo scenario include informazioni sul background del paziente:

- Demografica
- Sintomi
- Storia clinica del paziente (patologie, chirurgie...)
- Background sociale
- Domande del paziente
- Diagnosi e relativo piano terapeutico

Gli scenari venivano generati nel seguente modo:

- Estrazione di 60 passaggi, 20 per categoria, su argomenti come: demografica, sintomi e piano clinico.
- Per assicurarsi che gli estratti fossero pertinenti con lo scenario è stato utilizzato un LLM general purpose, PalM-2, per filtrare i passaggi estratti rimuovendo informazioni non adeguate al contesto.
- Infine la generazione dello scenario da paret di AMIE, sfruttando le informazioni estratte, segue un determinato modello.

Cambia slide e parla dell'immagine

Si parte con le informazioni di base sul paziente, sintomi e piano terapeutico per una specifica condizione clinica. Viene poi successivamente chiesto se le informazioni estratte siano coerenti con la condizione clinica di partenza. E infine viene generato un riepilogo dello scenario con tutte le informazioni del paziente e piani terapeutici.

Generatore dialogo simulato

L'altro componente è il generatore di dialogo simulato, che permette di simulare una conversazione tra i 3 agenti AI su una piattaforma virtuale seguendo i dati dello scenario che è stato generato in precedenza.

I tre agenti LLM, tutti interpretati da AMIE, avevano il compito di parlarsi tra loro per generare un dialogo plausibile seguendo istruzioni ben precise.

L'agente paziente ha il compito di rispondere in modo veritiero alle domande dell'agente medico e fare ulteriori domande nel caso in cui avesse ancora dubbi.

L'agente medico aveva il compito di essere empatico e di comprendere al meglio la storia clinica del paziente all'interno dell'ambiente virtuale, e di formulare domande che portassero a una corretta diagnosi e alla realizzazione di un piano terapeutico.

Il moderatore controlla l'andamento del dialogo tra i due agenti determinando quando la discussione ha raggiunto una naturale conclusione: l'agente medico ha trovato una diagnosi per il paziente, ha stilato un piano terapeutico e ha risposto a tutte le domande del paziente.

Cambia slide e parla dell'immagine dei prompt per i dialoghi

Le istruzioni per il paziente erano quelle di rispondere onestamente alle domande fatte dall'agente medico, rispettando lo scenario che gli era stato assegnato.

L'agente medico aveva il compito di essere empatico, rispondere alle domande del paziente in un solo turno, rispondere in maniera appropriata alle domande che puo fargli il paziente durante la consultazione.

Mentre le istruzioni per il moderatore erano quelle di terminare la conversazione quando l'agente medico ha finito la consultazione proponendo una diagnosi e un piano terapeutico e il paziente non ha più domande da fargli.

Feedback self-play

Per garantire dialoghi simulati di alta qualità, è stato implementato un framework di self-play per l'automiglioramento dei dialoghi diagnostici tramite l'introduzione di un quarto agente AI il critico, che è sempre interpretato da AMIE. E' a conoscenza della diagnosi corretta in modo da guidare l'agente medico, tramite feedback, a migliorare le sue prestazioni per future conversazioni.

Il critico ha valutato le risposte dell'agente medico secondo le seguenti metriche:

- Il medico mostra empatia e professionalità rispondendo alle domande e ai commenti del paziente
- Il medico evita domande ripetitive, o di fare troppe domande su informazioni già acquisite.
- Le risposte non devono far intendere all'interlocutore che si tratti di un agente AI. Quindi deve fare in modo che la conversazione scorra naturalmente
- L'agente medico ha posto domande in modo da individuare 2 diagnosi differenziali.

A seguito del feedback ricevuto, l'agente medico migliora le sue risposte verso la diagnosi corretta e un piano di trattamento clinico adeguato.

Istruzioni di fine-tuning

AMIE è stato sottoposto a un processo di fine-tuning per ottimizzare le risposte. Sono state fornite istruzioni specifiche in base al ruolo che AMIE deve interpretare nel ruolo di dottore come gestire la conversazione, creare sommari clinici sulla condizione del paziente. Il primo turno di fine-tuning ha utilizzato i dataset statici iniziali, mentre i successivi turni hanno sfruttato i dialoghi generati dal loop interno di self-play. AMIE col ruolo di paziente ha il compito di risponde con sincerità alle domande del medico. Invece nel ruolo di medico deve essere empatico e cercare di raccogliere più informazioni possibili per arrivare a una diagnosi. Tutte le attività, ad eccezione della generazioen di dialoghi e risposte estese includevano alcuni shot per dare più contesto al compito da eseguire.

Catena di ragionamento per inferenza on-line

La sfida principale da affrontare nell'ambito del dialogo diagnostico è quella di acquisire informazioni nell'incertezza, di conseguenza AMIE sfrutta un strategia basata su una catena di ragionamento prima di generare una risposta per ogni turno del dialogo. Per catena di ragionamento ci si riferisce a una serie di chiamate sequenziali al modello, ognuna dipendente dall'output precedente. Nello specifico si è usato un processo di ragionamneto a 3 step:

1. Analizzare le informazioni del paziente:
2. Data una conversazione, AMIE aveva il compito di riassumere i sintomi positivi e negativi e anche informazioni mediche relative ai familiari o al contesto sociale.
3. Produrre una diagnosi differenziale su qusete informazioni
4. Tenere traccia di informazioni mancanti per ottenere una diagnosi più accurata.
5. Stabilire il grado di confidenza della diagnosi attuale e stimarne la gravità.
6. Formulare risposte e azioni: Tenendo conto della conversazione e dell'output dello step 1
7. AMIE deve generare una risposta all'ultimo messaggio ricevuto dal paziente e fare ulteriori domande per estrapolare più informazioni per migliorare la diagnosi attuale
8. Se necessario raccomandare azioni immediate come una visita al pronto soccorso. se ha abbastanza confidenza sulla diagnosi attuale può presentarla.
9. Raffinare la risposta: AMIE raffina la risposta riguardando i suoi output precedenti per soddisfare determinati criteri come, la fattualità, evitare domande ripetitive, mostrare empatia e rispondere in modo comprensibile al paziente.

La strategia della catena di ragionamento ha permesso ad AMIE di migliorare progressivamente le sue capacità conversazionali in base alla conversazione corrente per arrivare ad una risposta ragionata.

Struttura dell'esperimento

L'esperimento è basato sugli esperimenti OSCE remoti che sono utilizzati nel mondo della medicina per valutare le prestazioni dei medici su vari scenari.

Nello studio abbiamo 2 agenti OSCE, uno è AMIE e l'altro e il medico che sono materia di valutazione da parte dei pazienti e di altri professionisti.

I due agenti OSCE interagiscono con il paziente simulato tramite una chat testuale sincrona. Il paziente attore, come nei dialoghi simulati, deve rispettare lo scenario che gli è stato assegnato, ovviamnete il paziente non sa se sta interagendo con il sistema AI o con una persona umana.

Dopo la fase delle consultazioni viene dato un questionario a tutti i pazienti per valutare la qualità della conversazione:

- Se il medico mostra empatia
- Se si mostra disponibile a rispondere alle domande poste dal paziente
- Come conduce la conversazione

C'è anche una fase di valutazione da parte di medici specialisti che valutano le prestazioni dei due agenti OSCE in base alla loro accuratezza della diagnosi Il modo in cui reperiscono informazioni, e valutano i piani terapeutici proposti. Anche in questo caso i medici specialisti non sanno chi stanno valutando.

Soggetti dell'esperimento

L'esperimento per AMIE ha coinvolto 20 medici certificati dall'albo 20 pazienti attori autorizzati per prendere parte a diagnosi attraverso una chat testuale. Gli scenari erano basati su casi canadesi, 60 scenari, e indiani, 75 scenari, e 14 per il Regno Unito, che sono stati ripartiti tra gli scenari indiani e canadesi. I medici avevano dai 3 a 25 anni di esperienza post-specializzazione I pazienti avevano background diversi tra di loro: studenti di medicina, cittadini e infermieri che avevano esperienza in partecipiazione a esami OSCE.

Sistema di valutazione

Lavori precedenti non permettevano di poter classificare correttamente l'accuratezza dei dialoghi e la qualità delle diagnosi. Dunque è stato realizzato un framework ad hoc per quanto riguarda la parte di valutazione ed è basato sullo stile di un OSCE remoto. Il framework tiene conto anche della qualità della conversazione struttura, completezza, ruoli, responsabilità

Consultazioni tramite chat

I pazienti interagivano con gli agenti OSCE tramite una chat testuale dove ogni paziente aveva al massimo 20 minuti per terminare la conversazione. I pazienti ovviamente non sapevano con quale dei due agenti OSCE stessero interagendo e dopo la consultazione veniva chiesto a loro di compilare i questionari sulla qualità della conversazione.

Questionari post consultazione

Dopo la conversazione sia i pazienti che i due agenti OSCE devono compilare dei questionari sulla valutazione della conversazione.

I pazienti davano una valutazione sulla qualità della conversazione l'empatia mostrata dal medico e se ha risposto in maniera esaustiva.

I due agenti OSCE (medico ed AMIE) invece dovevano fornire minimo 3 diagnosi differenziali con un massimo di 10 in base alle informazioni che sono riusciti ad estrarre durante la consultazione.

Valutazione da parte degli specialisti

Infine un pool di 23 specialisti, provenienti da varie parti del mondo per valutare il comportamento dei medici di base e di AMIE durante l'esperimento OSCE. Ogni specialista doveva dare una valutazione ad entrambi gli agenti OSCE in maniera anonima, quindi gli specialisti non sapevano chi stessero effettivamente valutando.

Ogni specialista ha valutato una consultazione in base alla sua specializzazione medica, quindi un cardiologo ha valutato una consultazione che riguardavi problemi cardiovascolari.

Ovviamente gli specialisti avevano accesso allo scenario completo con la diagnosi corretta e le ulteriori diagnosi accettabili.

I criteri di valutazione comprendo l'accuratezza, appropriatezza e comprensione della lista di DDx fornite, raccomandazioni su azioni da intraprendere durante la consultazione come citato precedentemente.

Modello di autovalutazione

E' stato introdotto anche un sistema di autovalutazione come alternativa economica all'opinione degli esperti.

Per avere un punto di partenza si è partiti da un sottoinsime della rubrica di valutazione PACES.

I risultati del processo di autovalutazione, che usa una strategia basata su una catena di ragionamento permettendo ad AMIE di valutare i dialoghi, era in linea con la valutazione degli esperti. L'autovalutazione è in linea con i risultati per quanto riguarda la qualità del dialogo e per accurateza della diagnosi.

Il modello di autovalutazione è stato usato anche per:

- Confronto dell'accuratezza delle DDx di AMIE e dei medici di base
- Confronto dell'accuratezza delle DDx tra i pazienti attori in Canada e in India per evidenziare eventuali differenze tra le due località
- “Isolare gli effetti dell'acquisizione delle informazioni e della loro interpretazione analizzando l'accuratezza delle DDx di AMIE quando gli viene fornita una consultazione di un medico di base.”
- Valutare l'efficienza nell'acquisizione di informazioni tra AMIE e medici di base analizzando l'accuratezza delle DDx man mano che il numero di turni nella conversazione aumenta.
- Valutare i benifici del self-play loop interno sulla qualità dei dialoghi prima e dopo il feedback.

Risultati autovalutazione (lascio o no?)

Questi grafici mostrano le diverse tecniche di autovalutazione sui 149 dialoghi condotti nell'esperimento. Il grafico a sinistra confronta le prestazioni dei vari metodi di autovalutazione.

La linea tratteggiata rappresenta la baseline randomica come punto di riferimento per i risultati degli altri metodi. Possiamo vedere che la tecnica della catena di ragionamento è la migliore e che la modalità di autovalutazione con 5 shot si avvicina parecchio.

Il grafico a destra invece ci mostra le differenze tra il metodo di autovalutazione e la valutazione degli specialisti. Entambi i dati superano la baseline randomica, indicata dalla linea nera tratteggiata, e abbiamo anche la baseline randomica con la linea verde tratteggiata mostra la preferenza randomica degli specialisti. Questo grafico ci mostra che il metodo di autovalutazione è in linea con la valutazione inter-specialista, validando la qualità del sistema di autovalutazione.

Valutazione qualità della conversazione

La qualità della conversazione è stata valutata in base al feedback ricevuto dai pazienti attori, i medici specialisti e l'output del modello di autovalutazione.

Valutazione pazienti attori (qualità conversazione)

(immagine valutazione) AMIE ha ricevuto una valutazione migliore rispetto ai medici su 24 criteri di valutazione su 26. Non si notano differenze significative per quanto riguarda rispetto della privacy e del paziente, e ammissione degli errori.

Valutazione degli specialisti (qualità della conversazione)

(immagine valutazione) I medici hanno valutato la qualità della conversazione e le risposte dei due agenti OSCE che hanno dato nei questionari in base al loro ambito medico. Nuovamente, AMIE ha ottenuto una valutazione migliore su 28 criteri su 32. Gli specialisti hanno preferito le diagnosi, piani terapeutici, rispetto a quelli dei medici di base. In questo caso si evidenzia una differenza sostanziale tra AMIE e i professionisti.

Analisi statistica, top-k accuracy

È stata valutata anche la top-k accuracy delle liste di DD presentate da AMIE e dai medici su tutti i 149 pazienti simulati La top-k accuracy è stata definita come la percentuale di casi dove la diagnosi corretta appare nelle top-k posizioni della lista delle DD. Una diagnosi candidata era considerata corretta se lo specialista la valutava come corretta, o molto vicina alla ground truth. La solidalità statistica è stata verificata tramite un test di boostrap con 10k campioni e una correzione sulla scoperta falsi positivi su tutti i k. I casi dove agente riceve “Impossibile da valutare / non applicabile” sono stati esclusi

Secondo grafico

Mostra la top-k accuracy sull'accuratezza delle DD in base al grado di corrispondenza valutato dagli specialisti.

- Somewhat related: la DD contiene qualcosa che è collegato alla diagnosi corretta ma difficilmente può portare alla diagnosi corretta.
- Relevant: la DD contiene qualcosa che è vicino alla diagnosi corretta e può tornare utile a determinarla con esattezza
- Extremely relevant: La DD contiene qualcosa che è molto vicino alla diagnosi corretta
- Exact match: la DD include la diagnosi corretta. Si nota una significativa differenza statistica per tutti i livelli di accuratezaz tranne per “Somewhat Related” tra AMIE e i medici.

Terzo grafico

Questo grafico ci mostra l'accuratezza delle DD calcolata dall'autovalutazione. É stato usato Med-PalM 2 per determinare se la diagnosi corretta appare nelle prime top-k posizioni della lista di diagnosi differenziali. Il grafico a) mostra i risultati di AMIE e dei medici di base rispetto alla diagnosi corretta. Il grafico b) mostra i risultati di AMIE e dei medici sulle diagnosi accettate.

C'è una differenza evidente nel primo grafico per quanto riguarda l'accuratezza sulla presenza della diangosi corretta. Sottolineando nuovamente la maggior accuratezza del modello rispetto ai medici di base.

Confronto con lavori precedenti

Studi passati confrontavano le prestazioni tra sistemi AI e medici e mostravano una somiglianza tra le prestazioni con a volte risultati migliori da parte dei sistemi AI. L'unica nota da tenere in considerazione e che questi studi lavoravano su input fissi per esempio veniva mostrata un immagine di una radiografia e si chiedeva ai due soggetti di fare una diagnosi basandosi su quell'immagine.

Mentre lo studio su AMIE è molto più complesso, raccoglie informazioni tramite il dialogo che devono poi essere elaborate, senza sfruttare informazioni già acquisite dagli umani, quindi non si sono valutate solo le sue capacità di inferenza ma anche la capacità di raccogliere informazioni tramite il dialogo. Anche la varietà degli scenari rappresenta una sfida significativa, permettendo di valutare le prestazioni del modello su più specialità mediche.

A differenza di studi precedenti il framework di valutazione si basa su strumenti già applicati nel mondo medico per la valutazione delle prestaizoni dei professionisti. Al momento questo è il primo studio che valuta un LLM utilizzando strumenti che si usano nel mondo reale. Il framework di valutaizone utilizzato è anche più granulare rispetto a quello di lavori precedenti.

Limitazioni dello studio

Una delle limitazioni più importanti è la consultazione tramite testo, visto che si perdono informazioni non verbali che si possono acquisire durante la consultazione. I medici tradizionalmnete abituati a consultazioni dal vivo e passare ad eseguire completamente delle diagnosi tramite interfaccia testuale può risultare scomodo.

I dialoghi simulati che hanno permesso di poter scalare le capacità di AMIE non riescono a cogliere la complessità dell'ambiente medico, visto che una patologia può manifestarsi in modi completamente diversi, la personalità del paziente, il suo background sociale e culturale. Anche l'obiettivo di arrivare a una DD accettabile per AMIE nel contesto reale potrebbe non essere possibile per alcune patologie.

I criteri di valutazione scelti non sono del tutto esaustivi e sono liberi ad interpretazione, anche se nell'esperimento si sono sfruttati dati e persone da varie parti del mondo si potrebbe espandere ulteriormente puntando a generalizzare ancora di più i risultati.

Il framework di valutazione si concentra sulla qualità della conversazione e dell'accuratezza della diagnosi, potrebbe essere migliorato ulteriormente con futuri studi per esempio valutando la soddisfazione del paziente, se il medico suggerisce cambi nello stile di vita del paziente.

Inoltre il framework non riesce a cogliere eventuali problemi di bias e di correttezza, per esempio alcuni medici cambiano stile comunicativo in base al background sociale e culturale del paziente compromettendo la qualità della consultazione.

Infine le prestazioni dei modelli LLM tendono peggiorare con lingue con poche risorse a disposizione.

Problematiche future

Uno dei problemi futuri è permettere ai modelli LLM di imparare da dati in costante evoluzione, soprattutto in ambito medico dove le conoscenze si aggiornano rapidamente.

Il bisogno di evitare un eccessivo affidamento ai modelli LLM per la diagnosi e invece cercare di sfruttarli come uno strumento da affiancare ai professionisti durante il loro lavoro, e di non basarsi esclusivamente sull'output fornito dal modello ma permettere anche di revisionare il processo di inferenza che ha portato a quell'output.

Un altro problema fondamentale è quello legato al bias e alla correttezza. Si spera che un eventuale utilizzo sul campo di un modello LLM sia privo di bias che alcuni medici possono avere. Magari permettendo a un team di professionisti di partecipare alle fasi di addestramento del modello garantendo maggior equità e correttezza.

Attualmente il passaggio da un prototipo a uno strumento che può essere sfruttato dai professionisti richiederebbe parecchio tempo. Sia per controllare eventuali problemi di sicurezza, controlli di qualità, conformità normativa prima di una qualunque implementazione.

The End