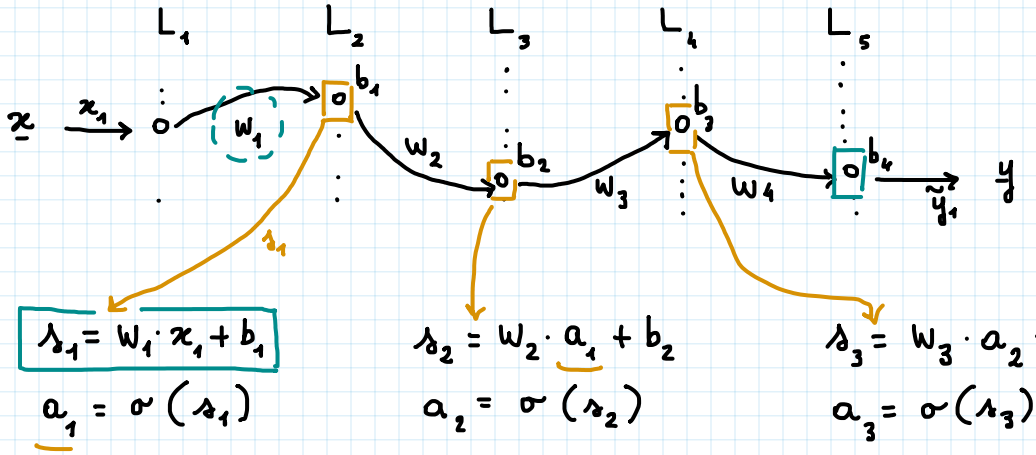
VANISHING GRADIENT PROBLEM

↳ o EXPLODING

i gradienti hanno/assumono VALORI troppo BASSI o troppo ALTI

problemi NUMERICI



* $s_4 = w_4 \cdot a_3 + b_4$, $\tilde{y}_1 = \sigma(s_4) = a_4$

Nel DATASET: ... (x_1, y_1) ... y_1 è il valore "ESATTO" o desiderato.

$|\tilde{y}_1 - y_1| \approx 0$?

$$\frac{d|x|}{dx} = \frac{|x|}{x}$$

$$\mathcal{L}(y, \tilde{y}) = |\tilde{y} - y|$$

$$\frac{\partial \mathcal{L}}{\partial w_1} = ?$$

$$\frac{\partial \mathcal{L}}{\partial a_4} = \frac{\partial |\tilde{y}_1 - y_1|}{\partial a_4} = \frac{|\tilde{y}_1 - y_1|}{\tilde{y}_1 - y_1}$$

$a_4 = \tilde{y}_1$

① $\frac{\partial \mathcal{L}}{\partial a_3} = \frac{\partial \sigma(s_3)}{\partial a_3}$

② $\frac{\partial \mathcal{L}}{\partial a_2}$

③ $\frac{\partial \mathcal{L}}{\partial a_1}$

$$s_4 = w_4 \cdot a_3 + b_4 \quad , \quad s_3 = w_3 \cdot a_2 + b_3$$

① $$\frac{\partial \mathcal{L}}{\partial a_3} = \frac{\partial \sigma}{\partial s} \frac{\partial (w_4 \cdot a_3 + b_4)}{\partial a_3} = \frac{d\sigma}{ds} \cdot w_4$$

② $$\frac{\partial \mathcal{L}}{\partial a_2} = \frac{\partial \sigma(s_3)}{\partial a_2} = \frac{d\sigma}{ds} \cdot \frac{\partial (w_3 \cdot a_2 + b_3)}{\partial a_2} = \frac{d\sigma}{ds} \cdot w_3$$

③ $$\frac{\partial \mathcal{L}}{\partial a_1} = \frac{\partial \sigma(s_2)}{\partial a_1} = \frac{d\sigma}{ds} \cdot \frac{\partial (w_2 \cdot a_1 + b_2)}{\partial a_1} = \frac{d\sigma}{ds} \cdot w_2$$

$$\frac{\partial \mathcal{L}}{\partial w_1} = \frac{\partial \mathcal{L}}{\partial a_4} \cdot d\sigma \cdot w_4 \cdot d\sigma \cdot w_3 \cdot d\sigma \cdot w_2 \cdot \frac{\partial \sigma(w_1 \cdot x_1 + b_1)}{\partial w_1} =$$

$$\frac{\partial \mathcal{L}}{\partial w_1} = \frac{|\tilde{y}_1 - y_1|}{\tilde{y}_1 - y_1} \cdot d\sigma\, w_4 \; d\sigma\, w_3 \cdot d\sigma\, w_2 \cdot d\sigma \cdot x_1 =$$

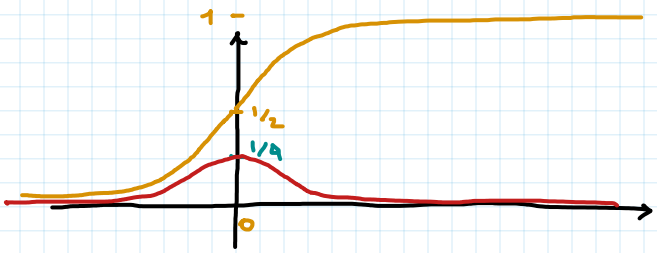
$$= ERR \cdot \boxed{(d\sigma)^4 \cdot w_4 \cdot w_3 \cdot w_2} \cdot x_1$$

↓

PROBLEMA di INSTABILITÀ

ESEMPIO:

$\sigma(x)$ SIGMOIDE $\quad \sigma(x) = \frac{1}{1+e^{-x}} \quad \sigma'(x) = \sigma(x)(1-\sigma(x))$



$|\sigma(x)| < 1 \qquad \sigma(0) = \frac{1}{2}$

$\sigma'(0) = \frac{1}{4}$

$|\sigma'(x)| \leq \frac{1}{4}$

Supponiamo $|w_i| < 1$: $\frac{\partial \mathcal{L}}{\partial w_1}$ diventa "piccola"

$$|\sigma'(x) \cdot w_i| < \frac{1}{4} \cdot 1 \qquad \left| \prod_{j=1}^{L} \sigma'(x) \cdot w_j \right| < \left(\frac{1}{4}\right)^L = \frac{1}{4^L}$$

MODELLI di LINGUAGGIO

$\underline{x}$ è un DOCUMENTO

↳ codifica ASCII, UTF-8, UTF-16 ...
NON SEMANTICA

WORD EMBEDDING → Word2Vec, BagOfWords, LLM

$\underline{x} \xrightarrow{\text{embedding}} \underline{y}$ VETTORE in uno spazio vett. $\mathbb{R}^N$ METRICO $(\mathbb{R}^N, d)$

OBIETTIVO:
Se $\underline{x}$, $\hat{\underline{x}}$ sono SEMANTICAMENTE VICINI,
allora $\underline{y}$ e $\hat{\underline{y}}$ sono VICINI. $d(\underline{y}, \hat{\underline{y}})$ è piccola

$\underline{x}$ DOCUMENTO · x_i "pezzo" chiamato TOKEN

token
tokenizer
INDICE 1 INDICE 2

VOCABOLARIO : { token, izer, ... } SEMANTICO

} codifica NON semantica

$\underline{x}(0), \underline{x}(1), \dots, \underline{x}(t)$ Vettori dell'embedding

OBIETTIVO: → Calcolare $P(\underline{x}(0)\,\underline{x}(1) \dots \underline{x}(t))$ DIFFICILE

→ Calcolare

$$P(\underline{x}(k) \mid \underline{x}(0)\,\underline{x}(1) \dots \underline{x}(k-1))$$

Riduciamo ancora le ipotesi

$$P(\underline{x}(k) \mid \underbrace{\underline{x}(i)\,\underline{x}(i+1) \dots \underline{x}(k-1)}_{\text{CONTESTO}})$$

Def: UNI-GRAMMI $P(\underline{x}(k) \mid \underline{x}(k-1))$

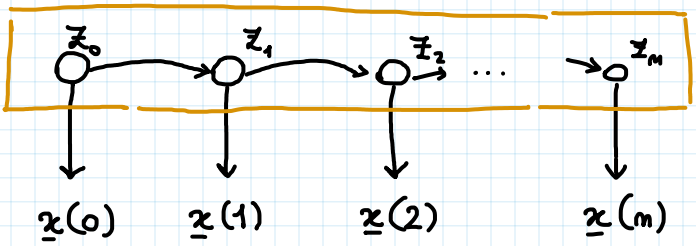
BI-GRAMMI $P(\underline{x}(k) \mid \underline{x}(k-2)\,\underline{x}(k-1))$

m-GRAMMI $P(\underline{x}(k) \mid \underline{x}(k-m)\,\underline{x}(k-(m+1)) \dots \underline{x}(k-1))$

PROPRIETÀ di MARKOV :

$$P(\underline{x}(k) \mid \underline{x}(0)\,\underline{x}(1) \dots \underline{x}(k-1)) = P(\underline{x}(k) \mid \underline{x}(k-1)) \quad *$$

↳ HIDDEN MARKOV MODELS : variabili LATENTI / NASCOSTE



z_i dipende solo da z_{i-1}

SEQUENZA OSSERVATA

Le z_i vengono chiamate "MEMORIA" di un HMM e soddisfano *

$$P(\underline{x}(k) \mid z_0 z_1 \dots z_k) \overset{*}{=} P(\underline{x}(k) \mid z_k)$$

Se $X = \underline{x}(0)\,\underline{x}(1) \dots \underline{x}(t)$ ·

$$P(X) = \sum_{Z = z_0 z_1 \dots z_t} P(X \mid Z)\, P(Z)$$

input stato nascosto

$$z_k = f(\underline{x}_{k-1}, \underline{z}_{k-1}) \quad f(\underline{x}_{k-2}, \underline{z}_{k-2}) \quad \dots$$

Per modellare f · $\underline{x}_t \in \mathbb{R}^N$ $\quad \underline{z}_t \in \mathbb{R}^M$

$W \in \mathbb{R}^{N \times M}$ $\quad \hat{W} \in \mathbb{R}^{M \times M}$ $\quad \underline{b} \in \mathbb{R}^M$

OUTPUT

$$\underline{z}_k = \sigma(W^T \underline{x}_{k-1} + \hat{W}^T \underline{z}_{k-1} + \underline{b})$$

$$\sigma(W^T \underline{x}_{k-2} + \hat{W}^T \underline{z}_{k-2} + \underline{b}) \quad \dots$$

Def: LIKELIHOOD (VEROSIMIGLIANZA): probabilità CONGIUNTA dei dati osservati $(\underline{x}_i)$ come funzione dei PARAMETRI del MODELLO

Sia $\underline{x} \mapsto f_\theta(\underline{x})$ la densità di probabilità di X allora

$$\theta \mapsto f_\theta(\underline{x}) =: \boxed{\mathcal{L}(\theta \mid \underline{x})}$$

θ: $W, \hat{W}, b$, f, ...

OBIETTIVO: Massimizzare la $\mathcal{L}(\theta \mid \underline{x})$ andando a modificare θ ...

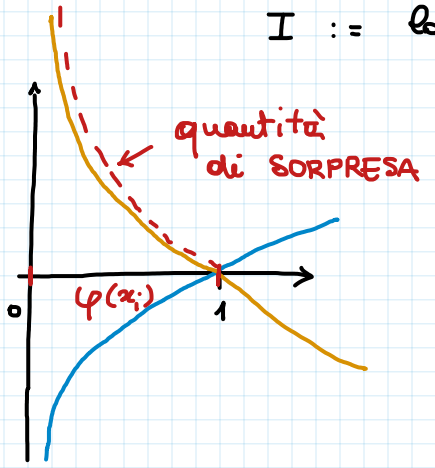
TEORIA dell' INFORMAZIONE

$X \sim \varphi(x_i)$ PROBABILITÀ di incontrare il dato x_i in una trasmissione da SORGENTE a DESTINAZ.

Def: QUANTITÀ di SORPRESA rispetto all' informazione portata da una SEQUENZA:

$$I := \log_2\left(\frac{1}{\varphi(x_i)}\right) = \boxed{-\log_2(\varphi(x_i))}$$

↑ UNITÀ di INFORMAZIONE: BIT



Se CONOSCO φ da osservatore, mi aspetto $\mathbb{E}_\varphi(X) =: h(\varphi)$

Def: ENTROPIA è il VALORE ATTESO della qtà di informazione:

$$h(\varphi) = -\sum_{i=0}^{N} \varphi(x_i) \log_2(\varphi(x_i))$$

Def: CROSS-ENTROPY (funzione di costo). Supponiamo che l'osservatore abbia NOTA una distrib. ψ dei dati. Quantifichiamo la SORPRESA nello scoprire che in realtà la distrib. è φ.

$\tilde{I} = -\log(\psi(x_i))$ ma in realtà $I = -\log(\varphi(x_i))$

$$\mathcal{L}(\tilde{I}, I) = -\sum_{i=0}^{N} \varphi(x_i)\log(\psi(x_i)) = \mathbb{E}_{\varphi}(\tilde{I})$$

φ: DISTRIBUZIONE VERA dei DATI

OBIETTIVO di ADDESTRAMENTO:

- Massimizzare $\mathcal{L}(\theta \mid \underline{x})$ (θ: $W, \hat{W}, b \dots$)

$$\mathcal{L}(\theta \mid \underline{x}) = P(\underline{x}(k) \mid \underline{z}_0 \underline{z}_1 \dots \underline{z}_k) = P(\underline{x}(k) \mid \underline{z}_k) =$$

$$= \prod_{i=0}^{m} P(x_i(k) \mid z_k^{(i)}) = \prod_{i=0}^{m} P(x_i(k) \mid z_k^{(i)})^{\#\{x_i = v_i\}}$$

$$-\log(P(\underline{x}(k) \mid \underline{z}_k)) = -\sum_{i=0}^{m} \log\left(P(x_i(k) \mid z_k^{(i)})^{\#\{x_i = v_i\}}\right) = \quad (J_i)$$

Quantità di SORPRESA / INFORMAZIONE

$$= -\sum_{i=0}^{m} J_i \log(P(x_i(k) \mid z_k^{(i)}))$$

CROSS-ENTROPY

$$\mathcal{L}(\tilde{I}, I) = -\sum_{i=0}^{m} P(x_i(k) \mid z_k^{(i)}) \log(\tilde{P}(x_i(k) \mid z_k^{(i)}))$$

($\tilde{P}$: $\mathcal{L}(\theta \mid \underline{x})$)

NUOVO OBIETTIVO: minimizzare CROSS-ENTROPY.

FUNZIONE di ATTIVAZIONE: SOFTMAX $\sigma(\underline{x})$ $\sigma: \mathbb{R}^N \to \mathbb{R}$

$$\sigma(x_i) = \frac{e^{x_i}}{\sum_{k=0}^{N} e^{x_k}}$$ (e^{x_i}: COMPONENTE; somma: NORMALIZZAZIONE)

$$\mathcal{L}(\tilde{I}, I) = -\sum_{i=0}^{m} \varphi(x_i) \log(\psi(x_i)) =$$

(ψ: dipende da $W, b \dots$; φ: REALE; $\psi(x_i) = \sigma(W\underline{x} + \hat{W}\underline{z} + b)$, x_i)

$$= -\sum_{i=0}^{n} \varphi(x_i) \log\left(\frac{e^{x_i}}{\sum_k e^{x_k}}\right) =$$

$$= -\sum_{i=0}^{n} \varphi(x_i)\left(x_i - \log\left(\sum_k e^{x_k}\right)\right) =$$

$\log\left(\sum_k e^{x_k}\right)$: non dipende da i

$\mathbb{E}(X)$

$$= -\sum_{i=0}^{n} x_i \varphi(x_i) + \sum_{i=0}^{n} \varphi(x_i) \cdot \log\left(\sum_k e^{x_k}\right)$$

$\sum_{i=0}^{n} \varphi(x_i) = 1$

$$= \log\left(\sum_k e^{x_k}\right) - \mathbb{E}_{\varphi}(X)$$

CROSS-ENTROPY + SOFTMAX