RETI GENERATIVE

NN è APPROX deterministica (MLP)

$$\underline{x} \xrightarrow{f} y \qquad \mathbb{R}^N \longrightarrow \mathbb{R}^M$$

approx di $f^* \in \mathcal{C}^0$

GENERATORE

$$\underline{x} \xrightarrow[NN]{f} \underline{z} \xrightarrow[NN]{g} y$$

approx stocastica

$g(\underline{z}, \theta_g)$ ← PESI e BIAS

RETI GENERATIVE DIFFERENZIABILI

$g(\underline{z}, \theta_g)$ è Differenziabile

Da SAMPLES di Z generiamo SAMPLES di Y

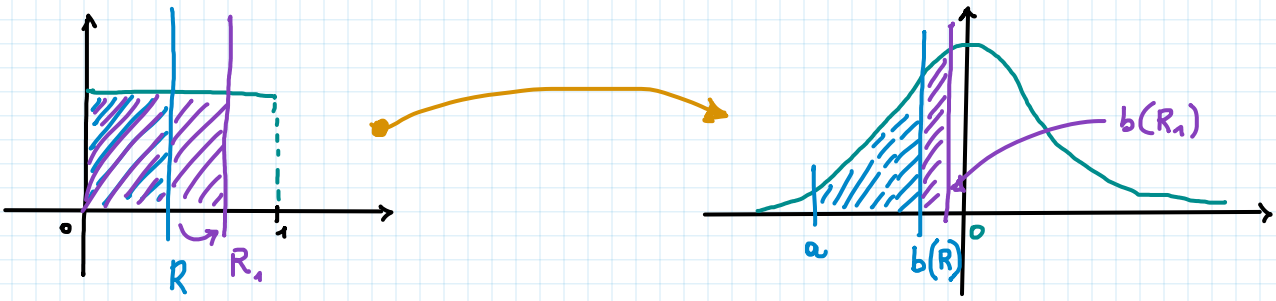
L'architettura della rete DETERMINA la FAMIGLIA di DISTRIBUZIONI

Sono i parametri θ_g che SELEZIONANO la distr. di Y.

OBIETTIVO: generare $Y \sim \mathcal{D}(\theta_g)$

METODO di INVERSIONE

Supponiamo di avere $X \sim \mathcal{U}(0,1)$ e vogliamo generare $Y \sim \mathcal{N}(0,1)$



OBIETTIVO

$$\int_0^R f(x)\,dx = \int_a^{b(R)} g(t)\,dt$$

$f(x)$: PDF della distr. conosciuta

$g(t)$: PDF della distr. obiettivo

Se $X \sim \mathcal{U}(0,1)$, $f(x) \equiv 1$ $\quad \forall x \in [0,1]$

① $\int_0^R f(x)\,dx = R$

Se $Y \sim \mathcal{N}(0,1)$, $g(t) = \frac{1}{2\pi} e^{-\frac{t^2}{2}}$

② $\int_a^{b(R)} g(t)\,dt = G(b(R)) - G(a)$! Se esiste G PRIMITIVA

① = ② $\quad R = G(b(R)) - G(a)$

da CALCOLARE

$b(R) = G^{-1}(R + G(a))$! Se G è INVERTIBILE

Se $Y \sim \mathcal{N}(0,1)$, G non si riesce a trovare.

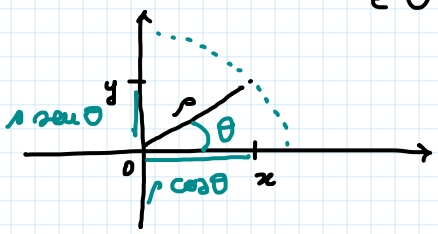
Passare a $\mathbb{R}^2$:

$g(x,y) = \frac{1}{2\pi} \cdot e^{-\frac{x^2+y^2}{2}}$ $\sim \mathcal{N}(0,1)$ in due variabili

Cambio di variabile COORD. POLARI $\rho = \sqrt{x^2+y^2}$ e θ

α

$\begin{cases} x = \rho \cos\theta \\ y = \rho \operatorname{sen}\theta \end{cases}$



$\det(J\alpha) = \rho$ $\qquad dx\,dy \rightsquigarrow \rho\,d\rho\,d\theta$

$g(\rho,\theta) = \frac{1}{2\pi} e^{-\frac{\rho^2}{2}}$

$\int_0^{\infty}\int_0^{2\pi} \frac{1}{2\pi} e^{-\frac{\rho^2}{2}} \rho\,d\rho\,d\theta = \int_0^{\infty} \frac{1}{2\pi} 2\pi \cdot e^{-\frac{\rho^2}{2}} \rho\,d\rho =$

$$= \left[-e^{-\frac{\rho^2}{2}} \right]_0^{\infty}$$

OBIETTIVO: trovare $b(R)$

$$\left[-e^{-\frac{\rho^2}{2}} \right]_0^{b(R)} = -e^{-\frac{b(R)^2}{2}} - \left(-e^{0}\right) = -e^{-\frac{b(R)^2}{2}} + 1$$

① = ②

$$R = -e^{-\frac{b(R)^2}{2}} + 1$$

$$b(R) = \pm\sqrt{-2\log(1-R)}$$

↳ Ma $\rho \geq 0$, quindi SCELGO $b(R) \geq 0$

$0 \leq R \leq 1$

$0 \leq 1-R \leq 1$

$\log(1-R) \leq 0$

$-2\log(1-R) \geq 0$

PROBLEMI si verificano nel caso in cui:

1) Non riusciamo a SPECIFICARE g
2) Non riusciamo a INTEGRARLA
3) Non riusciamo a INVERTIRLA

} DEEP LEARNING

Trovare g grazie alla NN:

$$\underline{x} \xrightarrow{f} \underline{z} \xrightarrow{g} \underline{y}$$

Le PDF: $p_{\theta_z}(z)$ $p_{\theta_y}(y)$

di z (VARIABILI LATENTI)

e y (da GENERARE)

$$p_{\theta_z}(z) \rightsquigarrow p_{\theta_y}(g(z))$$

① $\int_a^b p_{\theta_z}(t)\,dt = P(a \le Z \le b)$

↓

cambio di VARIABILE: ciò che la rete deve imparare

② $\int_a^b p_{\theta_y}(g(t))\,dt = \int_c^d p_{\theta_y}(y)\,dy$

DIFFERENZIABILE

① = ② $\quad p_{\theta_z}(z)\,dz = p_{\theta_y}(g(z))\,\boxed{|\det(J_g)|}\,dy$

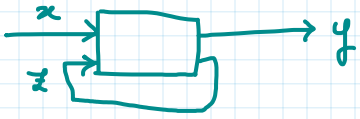
θ_y: parametri della RETE generatore

$$\boxed{p_{\theta_y}(y) = \frac{p_{\theta_z}(z)}{|\det(J_g)|} \cdot \frac{dz}{dy}}$$

ciò che VOGLIAMO ottenere

Se g è invertibile, $z = g^{-1}(y)$

↳ Cos'è z? $\quad z \longmapsto y$



AUMENTA la rete con INPUT EXTRA estratto da distr. fissata

MLE: Maximum Likelihood Estimation

$$\mathcal{L}(\theta_y \mid z) = p_{\theta_y}(y) = P(Y = y)$$

θ_y: PARAMETRI della RETE

Vogliamo trovare θ_y che MASSIMIZZANO $\mathcal{L}(\theta_y \mid z)$

↝ t.c. l'evento osservato $\{Y = y\}$ sia il PIÙ PROBABILE

$$\hat{\theta} = \arg\max_{\theta_y} \mathcal{L}(\theta_y | x)$$

$z = f(x)$

$z = g^{-1}(y)$

Nel nostro caso:

$$\hat{\theta} = \arg\max_{\theta_y} p_{\theta_y}(y) = \boxed{\arg\max_{\theta_y} \frac{p_{\theta_z}(z)}{|\det(Jg)|}}$$

Non si CALCOLA esplicitamente

INTERNAMENTE, il processo della NN rimane deterministico

$$x \xrightarrow{f} z \xrightarrow{g} y$$

ADDESTRAMENTO di f e g
- fw.
- back.
- SGD

APPARE come processo stocastico a un OSSERVATORE che NON ha accesso a Z.

ESEMPIO: Generare $Y \sim \mathcal{N}(\mu, \sigma^2)$ (parametri)

Assumo la conoscenza con $Z \sim \mathcal{N}(0,1)$

e poi $Y = \mu + \sigma Z$ (bias, peso)

PROBLEMA: Nel D_{train}, z NON c'è: $D_{train} = \{(x, y) \dots\}$

Quindi le reti generative fanno 2 COSE:

1) IMPARANO $p_{\theta_z}(z)$ — ENCODER

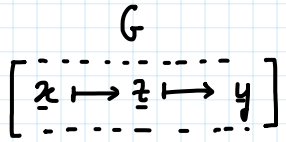
2) IMPARANO $g(z) = y$ ovvero $g(z, \theta_y)$ — DECODER

differenziabile

RETI AVVERSARIE GENERATIVE (GAN)

2 reti addestrate SIMULTANEAMENTE

G → Rete GENERATORE : $g(z, \theta_y)$



D → Rete DISCRIMINATORE: rete "deterministica" (MLP, CNN)

$x \longmapsto d(x, \theta_x)$ CLASSIFICAZIONE BINARIA → REAL / FAKE

Metodo di ADDESTRAMENTO è un GIOCO a SOMMA ZERO

- il PAYOFF di D è dato da $v(\theta_y, \theta_x)$
- il PAYOFF di G è dato da $-v(\theta_y, \theta_x)$

↳ i GIOCATORI vogliono MASSIMIZZARE il PAYOFF

ALGORITMO MINIMAX

$$g^* = \arg \min_g \max_d v(g, d)$$

(θ_y per g, θ_x per d)

$$v(\theta_y, \theta_x) = \mathbb{E}_{x \sim \text{data}} \left[\log(d(x, \theta_x)) \right] + \mathbb{E}_{g(x) \sim \text{model}} \left[\log(1 - d(g(x), \theta_x)) \right]$$

(* = log-likelihood; P = $d(x, \theta_x)$; 1−P = $d(g(x), \theta_x)$)

- $x \sim$ data → $x \in D_{train}$ → REALE
- $g(x) \sim$ model → $g(x)$ GENERATO

↑ LOSS AVVERSARIA

SE arriva a CONVERGENZA, ottengo il generatore g^* quando $d(x, \theta_x) \approx \frac{1}{2}$ per ogni x

↳ Non c'è garanzia di equilibrio.