Formulario FIA:

Distanza / Metrica

per $\mathbb{R}^N$, $N=1$ $\quad d(x,y) = |x-y|$

per $\mathbb{R}^N$, $N>1$ $\quad d(x,y) = \|\underline{x}-\underline{y}\|$

Palla chiusa / aperta: (Intorno sferico)

$\cdot$, $\leq$ è chiuso

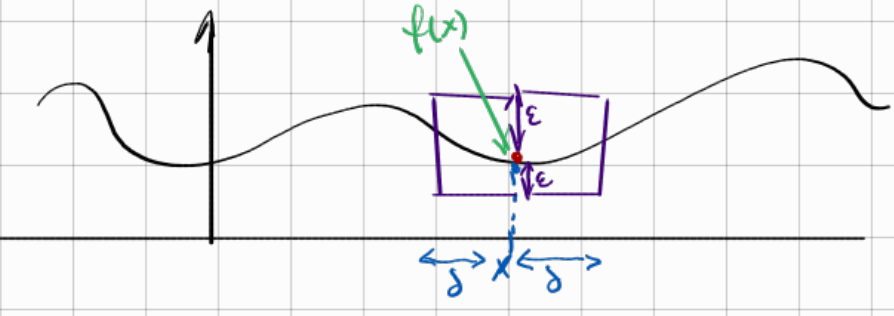
$$B(x_0, r) : \{ x \in \mathbb{R} \mid |x-x_0| \leq r, \ r>0 \} = (x_0 - r; x_0 + r)$$

Continuità Funzione:

Continuità per $f: \mathbb{R}^N \to \mathbb{R}$

$\underbrace{\forall \underline{x} \in \mathbb{R}^N}_{\text{dominio di } f}$, $\forall \varepsilon > 0 \quad \exists \delta > 0 : \forall \underline{y} \in \mathbb{R}^N$

$$\underbrace{\|\underline{x}-\underline{y}\| < \delta}_{d(x,y)<\delta} \Rightarrow \underbrace{|f(\underline{x}) - f(\underline{y})| < \varepsilon}_{d(f(x)-f(y))<\varepsilon}$$



Continua separatamente su x e y

Data $f: \mathbb{R}^2 \to \mathbb{R}$ si dice continua separatamente

$f: \mathbb{R}^2 \to \mathbb{R}$, si dice continua separatamente in x se, fissato y, f è continua.

$f(\uparrow \cdot \downarrow, y) \to$ è continua

Analogamente, una funzione è continua separatamente in y, se fissato x la funzione è continua

$f(x, \uparrow \cdot \downarrow) \to$ è continua

Una funzione $f: \mathbb{R}^2 \to \mathbb{R}$ può essere continua separatamente in x e y ma non in $\mathbb{R}^2$

Derivabile in una direzione

Sia $f: \mathbb{R}^N \to \mathbb{R}$ una funzione, si dice DERIVABILE in $x_0 \in \mathbb{R}^N$ e in una direzione $\underline{v} \in \mathbb{R}^N$, $\|\underline{v}\| = 1$ se esiste finito il limite del rapporto incrementale su $R(\underline{x}_0, \underline{v})$:

$$\frac{\partial f}{\partial \underline{v}}(\underline{x}_0) := \lim_{t \to 0} \frac{f(\underline{x}_0 + \underline{v} \cdot t) - f(\underline{x}_0)}{t}$$

Derivata parziale

Data $f: \mathbb{R}^N \to \mathbb{R}$, si chiama DERIVATA PARZIALE di f rispetto alla i-esima variabile, se esiste il limite del rapporto incrementale

$$\frac{\partial f}{\partial x_i}(\underline{x}_0) = \lim_{t \to 0} \frac{f(x_1, x_2, \dots, x_i \cdot t, x_{i+1}, \dots, x_N) - f(\underline{x}_0)}{t}$$

Gradiente: Siano $f: \mathbb{R}^N \to \mathbb{R}$ una funzione e $\underline{x}_0 \in \mathbb{R}^N$.

Se esistono tutte le derivate parziali in x_0, si può definire il gradiente di f come il vettore:

$$\nabla f(\underline{x}_0) = \left(\frac{\partial f}{\partial x_1}(x_0), \frac{\partial f}{\partial x_2}(x_0), \dots, \frac{\partial f(x_0)}{\partial x_N} \right)$$

direzione $\underline{e}_1$ — $\underline{e}_2$ — $\underline{e}_N$

Differenziale: $f: \mathbb{R}^N \to \mathbb{R}$; se esiste l'applicazione lineare in $\underline{x}_0 \in \mathbb{R}^N$ di direzione $\underline{v}$ detta DIFFERENZIALE

$$\forall \underline{v} \in \mathbb{R}^N: \quad d f_{\underline{x}_0}(\underline{v}) = \sum_{i=1}^{N} v_i \frac{\partial f}{\partial x_i}(x_0) = \underline{v} \cdot \nabla f(\underline{x}_0) = \frac{\partial f}{\partial \underline{v}}(\underline{x}_0)$$

allora f è DIFFERENZIABILE

Notazione: $d f_{\underline{x}_0} = \sum_{i=1}^{N} \frac{\partial f}{\partial x_i}(\underline{x}_0) \cdot dx_i$

PROPRIETÀ

$f: \mathbb{R}^N \to \mathbb{R}$ Differenziabile in $\underline{x}_0$ → continua in $\underline{x}_0$

$f: \mathbb{R}^N \to \mathbb{R}$ DIFFERENZIABILE in $\underline{x}_0$ → $\exists$ piano tg in $\underline{x}_0$

$f: \mathbb{R}^N \to \mathbb{R}$ è differenziabile → allora ∇f indica la direzione di massima crescita

$f: \mathbb{R}^N \to \mathbb{R}$ è differenziabile e $\underline{x}_0$ è un punto di massimo/minimo per f, allora $d f_{\underline{x}_0} = 0$ in tutte le direzioni.

se le derivate parziali in $B(x_0, r)$ con $r>0$, $r \in \mathbb{R}$ e tali derivate sono CONTINUE allora f è DIFFERENZIABILE in $\underline{x}_0$

Discesa del gradiente:

Per $f: \mathbb{R}^N \to \mathbb{R}$ $\quad \eta$ = learning rate

$N = 1$:

$$x_n = x_{n-1} - \eta f'(x_{n-1})$$

$N > 1$

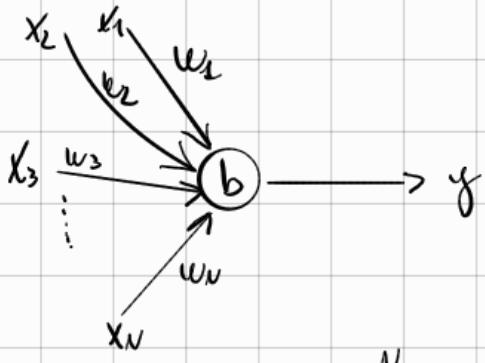
$$\underline{x}_n = \underline{x}_{n-1} - \eta \nabla f(\underline{x}_{n-1})$$

Strategie di terminazione

$\|\underline{x} - \underline{m}\| < \varepsilon \qquad \|f(\underline{x}) - f(\underline{m})\| < \varepsilon$

$\|\underline{x}_n - \underline{x}_{n-1}\| < \varepsilon \qquad \|\nabla f(\underline{x}_n)\| < \varepsilon \qquad n > T$

Percettrone / Neurone



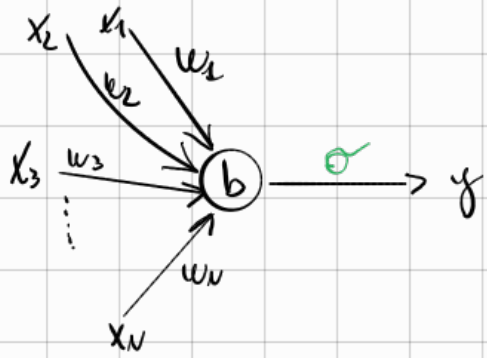
$f: \mathbb{R}^N \to \mathbb{R}$ $\quad f_{\underline{w},b}(\underline{x})$ $\quad \underline{w}, b$ sono parametri

$\underline{x} \in \mathbb{R}^N, \quad \underline{w} \in \mathbb{R}^N, \quad b \in \mathbb{R}, \quad y \in \mathbb{R}$

L'output è determinato da $\sigma(\underline{x} \cdot \underline{w} + b)$ → pre-attivazione

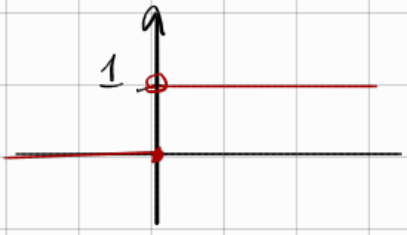
σ ↳ funzione d'attivazione

Funzioni d'attivazione:



$\sigma : \mathbb{R} \to \mathbb{R}$

$$\sigma(x) = \begin{cases} 0, & \text{se } x \leq 0 \\ 1, & \text{se } x > 0 \end{cases}$$

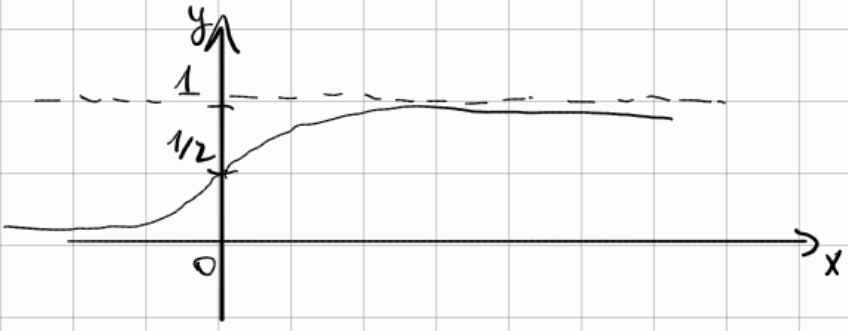


Funzione di Heaviside

Proprietà utili per una F.A.

$\sigma : \mathbb{R} \to \mathbb{R}$:
- non decrescenti
- continua, $\sigma \in \mathcal{C}^0(\mathbb{R})$
- limitata, $\exists L \in \mathbb{R}, L \geq 0 : \forall x \in \mathbb{R} \quad |\sigma(x)| \leq L$
- Continua, derivabile e derivate continue

— Sigmoide logistica



$\sigma : \mathbb{R} \to \mathbb{R}$ $\sigma \nearrow$ $\sigma \in \mathcal{C}^\infty(\mathbb{R})$ $|\sigma| \leq 1$

$\beta \in \mathbb{R}$

$\beta > 0$

$$\sigma_\beta(x) = \frac{1}{1 + e^{-\beta x}}$$

— Rectified Linear Unit (ReLU)



$\sigma : \mathbb{R} \to \mathbb{R}$, $\sigma \nearrow$, $\sigma \in \mathcal{C}^0(\mathbb{R})$

$$\sigma(x) = \max\{0, x\} = \begin{cases} 0, & \text{se } x \leq 0 \\ x, & \text{altrimenti} \end{cases}$$

$\frac{d\sigma}{dx}(x) = 0$ se $x \leq 0$ $\qquad$ $\frac{d\sigma}{dx}(x) = 1$ se $x > 0$

$\frac{\partial}{\partial x}$ $\frac{\partial}{\partial x}$

- SoftPlus - Smooth ReLU $\sigma: \mathbb{R} \to \mathbb{R}$ $\sigma \uparrow$ $\sigma \in \mathcal{C}^\infty(\mathbb{R})$

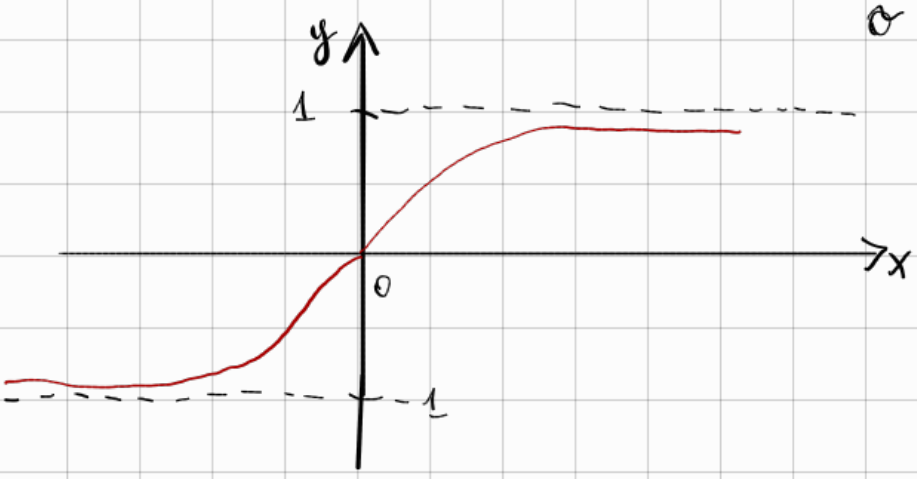


$$\sigma_\beta(x) = \frac{1}{\beta} \log(1 + e^{\beta x})$$

- Tangente iperbolica (tanh) $\sigma: \mathbb{R} \to \mathbb{R}$, $\sigma \nearrow$ $|\sigma| \leq 1$

$\sigma \in \mathcal{C}^\infty(\mathbb{R})$

$\beta \in \mathbb{R}$, $\beta > 0$



$$\sigma(x) = \tanh(\beta x)$$

Equazioni back propagation

$$\frac{\partial \mathcal{L}}{\partial w_{ij}} = \frac{1}{n} \sum_{k=1}^{n} \delta_j^{(\ell)} \cdot \sigma(s_i^{(\ell-1)})$$

$\sigma(s_i^{(\ell-1)})$ → attivazione neurone i, strato $\ell-1$

$\delta_j^{(\ell)}$ → errore neurone j, strato ℓ

$$\frac{\partial \mathcal{L}}{\partial b_j} = \frac{1}{n} \sum_{k=1}^{n} \delta_j^{(\ell)}$$

Algoritmo di addestramento

I parametri:

- Num epoche: epoche di addestramento
- $\eta > 0$, $\eta \in \mathbb{R}$ learning rate

Input: $D_{train} = \{ (\underline{x}^{(1)}, \underline{y}^{(1)}), \dots, (\underline{x}^{(n)}, \underline{y}^{(n)}) \}$ $n = |D|$

$\underline{x}^{(i)} \in \mathbb{R}^N$, $y^{(i)} \in \mathbb{R}^M$

Architettura della rete: L, numero di layer (strati)

N dim. input $n_1, n_2, \dots, n_L$, M dim. output

Algoritmo:

for $l = 1, 2, \dots, L, L+1$:

$W_0^{(l)}$, $b_0^{(l)}$ } Inizializzati in modo casuale θ_0

For $i = 1, \dots, N_{epoche}$:
For $\underline{x}^{(k)} \in D_{train}$

$\underline{a}_k^{(0)} = \underline{x}^{(k)}$
For $l = 1, \dots, L+1$:
$a_k^{(l)} = \sigma(W^{(l)T} \cdot a_k^{(l-1)} + b^{(l)})$] Passo forward

For $l = L, L-1, \dots, 1$:] Passo backward
Calcolare $\delta^{(l)}$

For $l = 1, \dots, L+1$:

$$w_i^{(\ell)} = w_{i-1}^{(\ell)} - \eta \cdot \frac{1}{n} \sum_{k=1}^{n} a_k^{(\ell-1)} \cdot \delta_k^{(\ell)}$$

$$b_i^{(\ell)} = b_{i-1}^{(\ell)} - \eta \cdot \frac{1}{n} \sum_{k=1}^{n} \delta_k^{(\ell)}$$

Aggiornamento parametri θ_i discesa grad

Teorema approx. Universale:

$$\max \| F(\underline{x}) - f(\underline{x}) \| < \varepsilon$$

F ↓ MLP

f ↓ f.o. $\in \mathcal{C}^0(\mathbb{R})$

$\sigma : \mathbb{R} \to \mathbb{R}$

$f : K \subseteq \mathbb{R}^N \to \mathbb{R}^M$

$f \in \mathcal{C}^0(\mathbb{R})$

Convoluzione

$$(x * w) = \int_{\mathbb{R}} x(a)\, w(t-a)\, da \qquad N=1$$

x segnale in input

w kernel

$$(x * w)(u, v) = \int_{\mathbb{R}^2} x(a,b)\, w(u-a, v-b)\, da\, db \qquad N=2$$

- Commutativa: $(x * w) = (w * x)$
- Linearità $(\lambda x + \mu y) * w = \lambda(x * w) + \mu(y * w)$

Cross correlation:

$$(x \bigstar w)(t) = \int_{\mathbb{R}} x(a)\, w(t + a)\, da$$

nella convoluzione è $t - a$

Flippando il kernel si ottiene la convoluzione

Funzione softmax (Modelli di linguaggio)

$$\sigma(\underline{x}_i) = \frac{e^{\underline{x}_i}}{\sum_{k=0}^{n} e^{\underline{x}_k}}$$

normalizza l'output secondo una distribuzione di probabilità $(0, 1)$